نقشهٔ جامع مدل‌های صوتی هوش مصنوعی

دسته‌بندی، مدل‌ها، ویژگی‌ها، مقایسه، هزینه و مجوز

سعید شیخ‌امیری · نوامبر ۲۰۲۶ · نسخهٔ ۱.۰

فهرست

پیش از خواندن ۰. خلاصهٔ مدیریتی در ۱۰ خط ۱. نقشهٔ کلی: چه دسته‌هایی وجود دارد؟

۲. معیارهای مقایسه (چک‌لیست واحد) ۳. دستهٔ ۱ — تبدیل متن به گفتار (TTS)

۴. دستهٔ ۲ — تشخیص گفتار (ASR / STT) ۵. دستهٔ ۳ — تبدیل صدا و کلونینگ (Voice Conversion)

۶. دستهٔ ۴ — تولید موسیقی ۷. دستهٔ ۵ — تولید افکت صدا و Foley

۸. دستهٔ ۶ — سنتز آواز (Singing Voice) ۹. دستهٔ ۷ — درک و تحلیل صدا (Audio LLM)

۱۰. دستهٔ ۸ — پردازش، جداسازی و بهبود صدا ۱۱. تحلیل هزینه: چطور واقعاً مقایسه کنیم؟

۱۲. مجوزها: جدول تصمیم ۱۳. راهنمای انتخاب بر اساس سناریو

۱۴. وضعیت فارسی: واقعیت‌ها و شکاف‌ها ۱۵. بنچمارک‌ها: کجا را نگاه کنیم؟

۱۶. ریسک‌ها و ملاحظات حقوقی/اخلاقی ۱۷. چک‌لیست ارزیابی عملی (قبل از انتخاب)

۱۸. منابع و لینک‌های کلیدی

پیش از خواندن

این گزارش را نوشتم چون مقایسهٔ مدل‌های صوتی از بیرون تقریباً ناممکن شده است. صفحهٔ هر فروشنده مدل خودش را با بدترین مدل رقیب مقایسه می‌کند، جدول‌های بنچمارک روی گفتار خوانده‌شدهٔ انگلیسی سنجیده می‌شوند و بعد «چندزبانه» نام می‌گیرند، و شرط مجوز سه کلیک دورتر از دکمهٔ دانلود پنهان است. کاری که در ادامه آمده تلاشی است برای گذاشتن کل حوزه روی یک صفحه: هشت دستهٔ کارکردی، مدل‌هایی که در هر دسته واقعاً مهم‌اند، هزینهٔ واقعی‌شان و نقاط حقوقی خطرناک.

دربارهٔ روش کار: مقایسه بر اساس «کارکرد» سازماندهی شده، نه معماری، چون تصمیم ساخت-یا-خرید در عمل این‌طور گرفته می‌شود. قیمت‌ها نرخ فهرست نوامبر ۲۰۲۶ و به دلار آمریکاست و مدام عوض می‌شوند؛ هر عددی که اینجا می‌بینید نقطهٔ شروع مذاکره است، نه پیش‌فاکتور. هرجا عددی را می‌شد با صفحهٔ رسمی فروشنده بررسی کرد، بررسی کردم و هرجا نشد، عدد تقریبی است و پیش از رفتن به بودجه باید تأیید شود. نسخهٔ مدل‌ها ماهانه عوض می‌شود، پس ممکن است تا زمانی که این را می‌خوانید جانشین یک مدل معرفی شده باشد.

تلاش کرده‌ام دربارهٔ بخش‌هایی که واقعاً نامطمئن‌اند صادق باشم: تأخیر به منطقه و بار شبکه بستگی دارد، WER به دامنه، و «پشتیبانی از ۹۹ زبان» معمولاً یعنی «پشتیبانی بد از ۹۹ زبان، به‌جز انگلیسی». هرجا داده کم بود، همان‌جا گفته‌ام.

> **هشدار دربارهٔ اعداد:** قیمت‌ها و نسخه‌ها ماهانه عوض می‌شوند. اعداد این سند تقریبی‌اند و باید پیش از قرارداد یا بودجه‌بندی از صفحهٔ رسمی قیمت تأیید شوند. جای مدل‌ها در جدول‌ها رتبهٔ مطلق نیست؛ ستون «مناسب برای» از رتبه مهم‌تر است.

---

۰. خلاصهٔ مدیریتی در ۱۰ خط

---

1. **هشت دستهٔ کارکردی** وجود دارد: ASR، TTS، تبدیل صدا (VC/کلونینگ)، تولید موسیقی، تولید افکت صدا، سنتز آواز، درک/تحلیل صدا، و پردازش و بهبود صدا.
2. **شکاف اصلی** بین «تجاری ابری» و «وزن باز» است: ابری‌ها کیفیت و پایداری بهتر و هزینهٔ متغیر دارند؛ وزن‌بازها هزینهٔ ثابت (GPU) و کنترل کامل، اما نگهداری و کیفیت متغیر.
3. در **TTS**، سه لایهٔ بازار شکل گرفته: مدل‌های فوق‌بیانی (ElevenLabs v3، Hume Octave)، مدل‌های فوق‌سریع برای ایجنت (ElevenLabs Flash، Deepgram Aura-2، Cartesia Sonic) و مدل‌های کوچک/باز (CosyVoice، Chatterbox، Piper، Kokoro).
4. در **ASR**، Whisper هنوز استاندارد «خوب و ارزان» است؛ اما در دقت انگلیسی، Parakeet/Canary (NVIDIA) و Deepgram Nova-3 و AssemblyAI جلوترند. برای فارسی، Whisper و Azure/Google همچنان گزینه‌های اصلی‌اند.

5. **موسیقی** به دو دنیای جدا تقسیم شده: محصولات مصرفی (Suno/Udio/Riffusion) و مدل‌های باز (ACE-Step، Stable Audio Open، MusicGen، YuE). کیفیت آواز و «آهنگ کامل» هنوز مزیت تجاری است.
6. **افکت صدا (SFX/Foley)** سریع‌ترین رشد را داشته: از تولید از متن تا Foley خودکار برای ویدیو (MMAudio، HunyuanVideo-Foley، ElevenLabs SFX).
7. **درک صدا** به سمت مدل‌های «Omni» رفته است: Kimi-Audio، Qwen3-Omni، Gemini، GPT-4o/5 audio؛ این‌ها دیگر «ASR» نیستند، دستیار صوتی‌اند.
8. **هزینه** را باید بر حسب واحد کار سنجید: TTS بر ۱۰۰۰ کاراکتر، ASR بر دقیقه، موسیقی بر تولید/دقیقه، و self-host بر GPU-ساعت. قاعدهٔ سرانگشتی: زیر ۵۰۰ ساعت صدا در ماه، API ارزان‌تر است؛ بالاتر از آن، GPU اختصاصی.
9. **مجوز** تلهٔ اصلی وزن‌بازهاست: CC-BY-NC (غیرتجاری)، Llama/Community License، و «کد باز اما وزن بسته». همیشه مجوز *وزن* را چک کنید، نه مجوز مخزن گیت‌هاب.
10. **ریسک حقوقی** جدی‌ترین موضوع کل حوزه است: کلونینگ صدا بدون رضایت، و مالکیت خروجی موسیقی. برای محصول تجاری، مسیر «مدل با مجوز تجاری صریح + قرارداد تأمین‌کننده» امن‌ترین است.

---

۱. نقشهٔ کلی: چه دسته‌هایی وجود دارد؟

دسته‌بندی بر اساس **کارکرد** (نه معماری) انجام شده، چون تصمیم خرید/انتخاب فنی معمولاً از کارکرد شروع می‌شود.

#	دسته	ورودی → خروجی	معیار موفقیت اصلی	نمونهٔ کاربرد
۱	**TTS / سنتز گفتار**	متن → گفتار	طبیعی‌بودن، بیان، تأخیر، کلونینگ	کتاب صوتی، دستیار، تبلیغ
۲	**ASR / تشخیص گفتار**	گفتار → متن	WER، دیاریزیشن، استریم، زبان	زیرنویس، تماس، تحلیل تماس
۳	**تبدیل صدا / کلونینگ (VC)**	صدا + هدف → صدای جدید	شباهت تیمبر، حفظ محتوا، بلادرنگ	دوبله، بازی، محتوای سازنده
۴	**تولید موسیقی**	متن/ملودی → موسیقی	موسیقیایی‌بودن، ساختار، آواز	آهنگ، پس‌زمینه، بازی
۵	**تولید افکت صدا (SFX/Foley)**	متن/ویدیو → صدا	همگامی با تصویر، واقع‌گرایی	فیلم، بازی، پادکست
۶	**سنتز آواز**	متن+ملودی → آواز	تلفظ، ویبراتو، احساس	تولید آهنگ، دمو
۷	**درک و تحلیل صدا**	صدا → معنا/برچسب/پاسخ	استدلال، برچسب‌گذاری، پاسخ‌گویی	دستیار صوتی، مانیتورینگ
۸	**پردازش و بهبود**	صدا → صدا	SNR، جداسازی، طبیعی‌بودن	پاک‌سازی، استم، مسترینگ

دو محور کمکی برای دسته‌بندی:

- **بر اساس سیگنال:** گفتار / موسیقی / صداهای عمومی و محیطی.
- **بر اساس جهت مدل:** مولد (TTS، موسیقی، SFX) در برابر تحلیل‌گر (ASR، برچسب‌گذاری، بازشناسی گوینده). مدل‌های Omni هر دو را دارند.

---

۲. معیارهای مقایسه (چک‌لیست واحد)

برای اینکه جدول‌ها قابل مقایسه باشند، هر مدل با این ۱۲ معیار سنجیده شده است:

معیار	توضیح	چرا مهم است
کیفیت ادراکی	MOS یا رتبهٔ آرنا (TTS Arena، Artificial Analysis)	نزدیک‌ترین معیار به «طبیعی‌بودن»
دقت (ASR)	WER روی مجموعه‌های تمیز/نویزی/لهجه‌دار	تصمیم اصلی برای رونویسی
تأخیر	TTFA (زمان تا اولین صدا) یا بلادرنگ‌بودن	تعیین‌کنندهٔ ایجنت صوتی
پوشش زبانی	تعداد زبان + کیفیت هر زبان	فارسی/چندزبانه
کلونینگ	صفر-شات، چند-شات، فاین‌تیون	شخصی‌سازی صدا
کنترل	احساس، سرعت، لحن، تلفظ، تگ‌های صوتی	کیفیت تولید محتوا
طول خروجی	چند ثانیه/دقیقه در یک درخواست	کتاب صوتی، پادکست
استریم	پشتیبانی WebSocket/بلادرنگ	تماس و ایجنت
سخت‌افزار	CPU/GPU، حافظه، سرعت RTF	هزینهٔ self-host
مجوز	Apache/MIT/CC-BY-NC/Community/اختصاصی	استفادهٔ تجاری
قیمت	به ازای کاراکتر/دقیقه/تولید	بودجه
بلوغ	مستندات، SDK، SLA، پایداری	ریسک عملیاتی

۳. دستهٔ ۱ — تبدیل متن به گفتار (TTS)

۳.۱. تصویر کلی بازار

سه نسل مدل در TTS امروز هم‌زمان فعال‌اند:

- **نسل ۱ (اتصال‌گرا):** Tacotron/FastSpeech/VITS — سریع و سبک، کیفیت متوسط، هنوز در محصولات جاسازی‌شده و زبان‌های کم‌منبع رایج.
- **نسل ۲ (انتشار/دیفیوژن و LLM-محور):** XTTS، F5-TTS، CosyVoice، Chatterbox، Orpheus، Dia — کلونینگ صفر-شات و بیان بالا.
- **نسل ۳ (گفت‌وگوی کامل):** TTS — Gemini، GPT-4o audio، Moshi، CSM به‌عنوان بخشی از یک مدل گفت‌وگو، با درک زمینه.

۳.۲. مدل‌های تجاری (API / SaaS)

مدل / سرویس	ویژگی شاخص	تأخیر	زبان	کلونینگ	قیمت تقریبی	مناسب
ElevenLabs v3	بیانی‌ترین مدل بازار؛ تگ‌های احساسی (`[whispers]` , `[laughs]`)؛ ۷۰+ زبان	۰.۵–۱ ثانیه (غیراستریم)	+۷۰	فوری (۱ دقیقه نمونه) + حرفه‌ای	۰.۰۶–۰.۲۴ دلار / هزار کاراکتر؛ پلن‌ها از ۵ دلار تا ۱,۳۲۰ دلار/ماه	کتاب ص تبلیغ، د احساسی
ElevenLabs Flash v2.5	نسخهٔ فوق‌سریع همان موتور	۷۵ میلی‌ثانیه	+۳۲	محدود	ارزان‌تر از v3	ایجنت صوتی،
ElevenLabs Turbo v2.5	تعادل سرعت/کیفیت	۲۵۰–۳۰۰ میلی‌ثانیه	+۳۲	بله	متوسط	چت‌بات صوتی
OpenAI gpt-4o-mini-tts	دستورپذیری با پرامپت («با لحن آرام و جدی»)؛ یکپارچه با API	۰.۵ ثانیه	۵۰ (کیفیت متغیر)	خیر	۰.۰۱۵ دلار/دقیقه صدا	محصولا OpenAI
OpenAI tts-1 / tts-1-hd	ساده، پایدار، ۱۳ صدا	سریع	۵۰	خیر	۱۵ و ۳۰ دلار برای هر میلیون کاراکتر	MVP و پروتوتای
Google Chirp 3 HD	صدای طبیعی، پوشش گسترده، GCP	۰.۳ ثانیه	+۵۰	Custom Voice (سازمانی)	۳۰ دلار / میلیون کاراکتر	سازمانی
Google Gemini TTS	کنترل با پرامپت زبان طبیعی، چند-اسپیکر	متوسط	+۲۴	خیر	بر پایهٔ توکن صوتی (پیش‌نمایش)	تجربه‌ها مکالمه‌ای
Azure Neural TTS	پوشش رسمی fa-IR؛ SSML کامل؛ استریم	۰.۲ ثانیه	+۱۴۰	Custom Neural Voice	۱۵ دلار برای هر میلیون	فارسی سازمانی

مدل / سرویس	ویژگی شاخص	تأخیر	زبان	کلونینگ	قیمت تقریبی	مناسب
					کاراکتر (:HD ۳۰ دلار)	
Amazon Polly	ارزان، پایدار، Generative voices	۰.۳ ثانیه	+۴۰	Brand Voice	۴ دلار استاندارد، ۱۶ دلار نرال، ۳۰ دلار جنراتیو	مقیاس AWS
Cartesia Sonic-3	فوق‌سریع و کم‌هزینه برای مکالمه؛ کیفیت خوب	۴۰ میلی‌ثانیه	+۴۰	Instant clone	۲۰–۴۰ دلار / میلیون کاراکتر	ایجنت ز
Deepgram Aura-2	مخصوص ایجنت؛ تأخیر پایین؛ SLA	۲۰۰ میلی‌ثانیه	انگلیسی‌محور	خیر	۳۰ دلار / میلیون کاراکتر	تماس، پشتیبانی
Hume Octave	کنترل احساس و «بازیگری» با توصیف	متوسط	+۱۰	بله	بر کاراکتر، گران‌تر از میانگین	محتوای نمایشی
PlayHT Play 3.0	کلونینگ سریع، پوشش زبان خوب	۰.۳ ثانیه	+۳۰	بله	۳۹ دلار/ماه شروع؛ API کاراکتری	پادکست ویدیو
LMNT	فوق‌سریع، مینیمال	۵۰ میلی‌ثانیه	+۱۰	بله	۰.۰۳ دلار/هزار کاراکتر	استریم کم‌تأخیر
Rime	صداهای «شخصیت‌محور» و محاوره‌ای	۰.۲ ثانیه	+۱۰	بله	کاراکتری	بازی، شخصیت
MiniMax Speech-2.6	کیفیت بالا با قیمت تهاجمی؛	متوسط	+۴۰	بله	ارزان (رقابتی با	بازار قیمت‌ح

مدل / سرویس	ویژگی شاخص	تأخیر	زبان	کلونینگ	قیمت تقریبی	مناسب
	۴۰+ زبان				ElevenLabs)	
Fish Audio S1	کلونینگ سریع، قیمت پایین، اکوسیستم باز	متوسط	+۱۳	بله	۱۵ دلار / میلیون کاراکتر	سازندگار محتوا
Speechify / Murf / WellSaid / Resemble	محصول‌محور (استودیو، تیم، برند)	متوسط	۲۰–۵۰	بله	اشتراک ۲۰– ۱۰۰ دلار/ماه	تیم‌های محتوا

نکتهٔ قیمت: قیمت مؤثر TTS را با «هزینه به ازای یک ساعت صدا» بسنجید. یک ساعت گفتار۹۰,۰۰۰ کاراکتر (فارسی/انگلیسی متوسط). یعنی ۱۵ دلار برای هر میلیون کاراکتر **۱.۳۵ دلار به ازای هر ساعت صدا**؛ ۳۰ دلار برای هر میلیون کاراکتر **۲.۷ دلار**؛ ElevenLabs در پلن پایین تا **۱۰–۲۰ دلار در ساعت** می‌رسد.

۳.۳. مدل‌های با وزن باز / متن‌باز

مدل	پارامتر	زبان	کلونینگ	مجوز	سخت‌افزار	نقطهٔ قوت	خ
82M-Kokoro	۸۲M	۸ (en, ja, zh, es, fr, hi, it, pt)	خیر (voicepack)	Apache 2.0	CPU هم اجرا می‌شود	کیفیت/هزینهٔ بی‌نظیر؛ فوق‌سریع	ب ک ز م
Piper	۱۰–۶۰M	۳۰+ (شامل fa_IR)	خیر	MIT	Raspberry Pi	سبک، آفلاین، چندزبانه	ح م
XTTS-v2 (Coqui)	۴۶۷M	۱۷	۶ ثانیه نمونه	CPML (غیرتجاری)	۴–۶GB VRAM	کلونینگ چندزبانهٔ بالغ	م غ ف ن
F5-TTS	۳۳۶M	en, zh (+fainetune)	صفر-شات	کد MIT / وزن CC-BY-NC	۶–۸GB	کیفیت بالا، آموزش‌پذیر	و غ ز م
Chatterbox (Resemble)	۰.۵B	۲۳ + en زبان (نسخهٔ چندزبانه)	بله	MIT	۶–۸GB	احساس قابل تنظیم، واترمارک Perth	ک چ نا
Dia-1.6B (Nari)	۱.۶B	en	بله	Apache 2.0	+۱۰GB	دیالوگ چندنفره، خنده/آه	ف ا ک
Orpheus-3B (Canopy)	۳B	en + چند نسخهٔ زبانی	بله	Apache 2.0	+۱۲GB	تگ‌های احساسی، استریم ۲۰۰ میلی‌ثانیه	س

مدل	پارامتر	زبان	کلونینگ	مجوز	سخت‌افزار	نقطهٔ قوت	خ
Sesame 1B-CSM	۱B	en	بله	Apache 2.0	۸GB	زمینهٔ مکالمه، طبیعی	ا غ ک د
VibeVoice (Microsoft)	۱.۵B / ۷B	en, zh	بله	MIT	۸–۱۶GB	تا ۴ گوینده، تا ۹۰ دقیقه	ز م
Higgs Audio v2 (Boson)	۳B	چندزبانه	بله	Apache (کد) / وزن باز	+۱۲GB	کیفیت بالا، موسیقی/ آواز	م س
IndexTTS-2 (Bilibili)	۱B	zh, en	صفر-شات	Apache 2.0	۸GB	کنترل احساس و مدت	ز م
CosyVoice 2/3 (Alibaba)	۰.۵B	zh, en, ja, ko + گویش‌ها	بله	Apache 2.0	۴–۶GB	استریم ۱۵۰ میلی‌ثانیه، کیفیت صنعتی	ف ن
Fish Speech / OpenAudio	۰.۵B	۱۳	بله	کد Apache / وزن CC-BY-NC-SA	۶GB	چندزبانه، کلونینگ سریع	و غ
MegaTTS3	۰.۴۵B	zh, en	بله	Apache 2.0	۶GB	کلونینگ خوب، سبک	د
Zonos (Zyphra)	۱.۶B	en + ۷	بله	Apache 2.0	۸GB	کنترل احساس،	ف ن

مدل	پارامتر	زبان	کلونینگ	مجوز	سخت‌افزار	نقطهٔ قوت	خ
						صدای خوب	
Bark (Suno)	۱B	+۱۳	بله	MIT	۶GB	صداهای غیرکلامی، موسیقی	نا ک
Parler-TTS	۰.۹B	en	خیر	Apache 2.0	۶GB	کنترل با توصیف متنی	ا ک م
Spark-TTS	۰.۵B	zh, en	بله	Apache 2.0 (کد)	۴GB	سبک، کنترل‌پذیر	ز م
MOSS-TTSD / FireRedTTS-2	۱–۳B	zh, en	بله	Apache 2.0	۸–۱۲GB	دیالوگ طولانی، پادکست	ز م

جمع‌بندی TTS:

- **بهترین کیفیت مطلق:** ElevenLabs v3، Hume Octave، MiniMax Speech (تجاری) و در باز: Higgs Audio v2، IndexTTS-2، Chatterbox.
- **بهترین نسبت کیفیت/هزینه در باز:** 82M-Kokoro (بدون کلونینگ) و CosyVoice-2/3 (با کلونینگ).
- **بهترین برای ایجنت بلادرنگ:** ElevenLabs Flash، Deepgram Aura-2، Cartesia Sonic-3، در باز: CosyVoice-2، Orpheus.
- **بهترین برای فارسی:** ElevenLabs، Google Chirp 3، Azure Neural/Custom Neural (با تست)، Amazon Polly؛ در باز: Piper fa_IR و مدل‌های جامعه‌محور VITS/Coqui آموزش‌دیده روی ManaTTS.

۴. دستهٔ ۲ — تشخیص گفتار (ASR / STT)

۴.۱. مدل‌های تجاری

سرویس / مدل	قیمت تقریبی	WER (انگلیسی تمیز)	استریم	دیاریزیشن	زبان	نکته
OpenAI whisper-1	۰.۰۰۶ دلار/ دقیقه	۸–۱۲٪	خیر	خیر	۹۹	ارزان، ساده، بدون ویژگی
OpenAI gpt-4o-transcribe	۰.۰۰۶ دلار/ دقیقه	۵–۸٪	محدود	خیر	+۵۰	مقاوم به نویز، خلاصه‌سازی
OpenAI gpt-4o-mini-transcribe	۰.۰۰۳ دلار/ دقیقه	۷–۱۰٪	محدود	خیر	+۵۰	ارزان‌ترین OpenAI
Deepgram Nova-3	−۰.۰۰۴۳ ۰.۰۰۷۷ دلار/ دقیقه	۵–۷٪	بله (خوب)	بله	+۳۰	استاندارد ایجنت/ تماس
AssemblyAI Universal-3	−۰.۰۰۲۵ ۰.۰۰۴۵ دلار/ دقیقه	۵–۷٪	بله	بله	۹۹	ویژگی‌های تحلیل مکالمه
Speechmatics	−۰.۰۰۱۷ ۰.۰۰۳۶ دلار/ دقیقه	۶–۸٪	بله	بله	+۵۰	دقت بالا در لهجه، اروپا
Soniox	۰.۰۰۱–۰.۰۰۲ دلار/دقیقه	۶–۹٪	بله	بله	+۶۰	ارزان، استریم
Gladia	۰.۰۰۲۵ دلار/ دقیقه	۷–۹٪	بله	بله	۱۰۰	ساده، اروپا
Rev AI	۰.۰۲ دلار/ دقیقه (AI)	۶–۸٪	خیر	بله	+۳۰	کیفیت + خدمات انسانی

سرویس / مدل	قیمت تقریبی	WER (انگلیسی تمیز)	استریم	دیاریزیشن	زبان	نکته
Google Chirp 3	۰.۰۱۶ دلار/دقیقه	۶–۹٪	بله	بله	۱۲۵	یکپارچگی GCP
Azure Speech	۰.۰۱۷ دلار/دقیقه (real-time)	۶–۹٪	بله	بله	+۱۰۰	فارسی رسمی، SSML
Amazon Transcribe	۰.۰۲۴ دلار/دقیقه	۷–۱۰٪	بله	بله	۱۰۰	AWS، Tiered
ElevenLabs Scribe v2	۰.۰۰۶۷ دلار/دقیقه	۴–۶٪	خیر	بله	۹۹	دقت بالا، تمیزکاری
Mistral Voxtral	۰.۰۰۳–۰.۰۰۶ دلار/دقیقه	۶–۸٪	خیر	خیر	۸	ارزان، اروپا

۴.۲. مدل‌های با وزن باز

مدل	پارامتر	مجوز	WER انگلیسی	زبان	سرعت	نکته
Whisper large-v3	۱.۵B	MIT	۷–۹٪	۹۹	متوسط	استاندارد طلایی باز؛ مقاوم
Whisper large-v3-turbo	۸۰۹M	MIT	۸–۱۰٪	۹۹	×۸ سریع‌تر	بهترین تعادل
distil-whisper large-v3.5	۷۵۶M	MIT	۹–۱۱٪	en	×۶ سریع	انگلیسی
NVIDIA Parakeet-TDT-0.6B v3	۰.۶B	CC-BY-4.0	۵–۶٪	۲۵ (اروپایی)	بسیار سریع	صدر جدول Open ASR
NVIDIA Canary-2.5B-Qwen	۲.۵B	CC-BY-4.0	۵.۶٪	en	متوسط	دقت بالا + LLM
NVIDIA Canary-1B-v2	۱B	CC-BY-4.0	۶–۷٪	۲۵	سریع	ترجمهٔ گفتار هم دارد
Kyutai STT	۱B / ۲.۶B	CC-BY-4.0	۶–۸٪	en, fr	استریم	بلادرنگ
Moonshine	۲۷– ۶میلیون	MIT	۹–۱۲٪	en	فوق‌سریع	لبه (edge)
Vosk	۵۰– ۵۰۰M	Apache 2.0	۱۰–۱۵٪	۲۰+ (شامل fa)	CPU	آفلاین کوچک
MMS / Wav2Vec2	۳۰۰M	MIT	متغیر	۱۱۰۰+ (شامل fa)	متوسط	پوشش زبانی بی‌رقیب
SenseVoice	۲۳۴M	Apache 2.0	۷–۹٪	zh, en, ja, ko	فوق‌سریع	احساس + رویداد صوتی

مدل	پارامتر	مجوز	WER انگلیسی	زبان	سرعت	نکته
Qwen3-ASR	۱.۷B–۸B	Apache 2.0	۵–۷٪	۵۲	متوسط	دقت بالا، LLM-محور
Step-Audio 2 mini ASR	۸B	Apache 2.0	۵–۷٪	+۳۰	کند	بخشی از مدل Omni

جمع‌بندی ASR:

- **دقت مطلق:** Canary-Qwen-2.5B، Deepgram Nova-3، AssemblyAI Universal-3، ElevenLabs Scribe v2.
- **ارزان‌ترین ابری:** Speechmatics batch، Gladia، Soniox.
- **بهترین باز برای self-host:** Whisper large-v3-turbo (عمومی)، Parakeet-TDT (سرعت + دقت اروپایی)، Canary (دقت).
- **فارسی:** Whisper large-v3 (WER ۱۰–۱۵٪ بسته به دامنه)، Speechmatics، Google fa-IR، Azure fa-IR، Vosk fa (سبک/کم‌دقت)، NVIDIA NeMo Persian (اگر دادهٔ آموزش داشته باشید).

---

۵. دستهٔ ۳ — تبدیل صدا و کلونینگ (Voice Conversion)

مدل / سرویس	نوع	مجوز/قیمت	کیفیت شباهت	بلادرنگ	نکته
RVC (Retrieval-based VC)	وزن باز	MIT	بالا (با ۱۰–۳۰ دقیقه داده)	بله (۹۰ میلی‌ثانیه)	پرکاربردترین در جامعه؛ آموزش آسان
so-vits-svc	وزن باز	AGPL	بالا	تقریباً	محبوب برای آواز
OpenVoice v2 (MyShell)	وزن باز	MIT	متوسط	بله	کلونینگ تیمبر + چندزبانه، سبک
Seed-VC	وزن باز	Apache 2.0	بالا	بله	صفر-شات، آواز و گفتار
GPT-SoVITS	وزن باز	MIT	بالا	خیر	کیفیت بالا با ۱ دقیقه داده
Chatterbox VC	وزن باز	MIT	بالا	خیر	همراه TTS همان خانواده
ElevenLabs Voice Changer	ابری	اشتراکی	بالا	بله	ساده، کیفیت خوب
Respeecher	ابری/ استودیو	سازمانی (گران)	بسیار بالا	خیر	فیلم/سریال، مجوز صدا
Altered Studio	ابری	اشتراکی	بالا	بله	دوبله و بازی
Voice.ai / Kits VC	ابری/ دسکتاپ	فریمیوم	متوسط–بالا	بله	مصرف‌کننده

نکات کلیدی:

- **کلونینگ = ریسک حقوقی.** در بسیاری از حوزه‌ها (EU AI Act، قوانین ایالتی آمریکا) افشای «صدای مصنوعی» و رضایت صاحب صدا الزامی است. واترمارک (مثل Perth در Chatterbox) و لاگ رضایت را جدی بگیرید.
- **RVC** برای «شخصی‌سازی سریع» بهترین نسبت هزینه/کیفیت است؛ **Seed-VC** برای صفر-شات بدون آموزش.
- برای آواز، **RVC + so-vits-svc** همچنان استاندارد جامعه است؛ برای تولید کامل آهنگ، مسیر Suno/ACE-Step ساده‌تر است.

---

۶. دستهٔ ۴ — تولید موسیقی

۶.۱. تجاری / مصرفی

سرویس	نسخه	ویژگی	قیمت تقریبی	مالکیت خروجی
Suno	v5	آهنگ کامل با آواز، سبک‌های متنوع، ویرایش بخش‌ها	Free (۵۰ کردیت/روز، غیرتجاری)؛ Pro ۱۰ دلار/ماه؛ Premier ۳۰ دلار/ماه	در پلن پولی، تجاری (با شرایط)
Udio	v2/v3	کیفیت صوتی بالا، کنترل سبک	۱۰–۳۰ دلار/ماه	تجاری در پلن‌ها؛ پس از توافق با ناشران
Riffusion	FUZZ	رایگان/فریمیوم، تولید سریع	رایگان + پلن	متغیر
Stable Audio 2.5 (Stability)	2.5	تولید تا ۳ دقیقه، لوپ، تبدیل صدا	کردیت API	تجاری با مجوز
Google Lyria 2/3	Vertex/Gemini	موسیقی پرکیفیت، ابزارهای حرفه‌ای	بر دقیقه/توکن	تجاری
MiniMax Music 2	—	آهنگ کامل، ارزان	API ارزان	تجاری
Mureka	V8	آهنگ کامل + آواز	اشتراکی	تجاری
ElevenLabs Music	—	موسیقی با مجوز داده، تمرکز تجاری	اشتراکی	تجاری (مدعی مجوز کامل)
Adobe Firefly Soundtrack	—	ایمن از نظر حق نشر	کردیت Creative Cloud	تجاری

سرویس	نسخه	ویژگی	قیمت تقریبی	مالکیت خروجی
Soundraw / Beatoven / AIVA / Boomy	—	موسیقی رویالتی-فری برای ویدیو	۱۰–۳۰ دلار/ماه	تجاری

۶.۲ وزن باز

مدل	پارامتر	مجوز	طول خروجی	آواز	نکته
ACE-Step	۳.۵B	Apache 2.0	تا ۴ دقیقه	بله (۱۹ زبان)	کامل‌ترین گزینهٔ باز برای «آهنگ کامل»
Stable Audio Open 2.0	۱B	Stability Community (تجاری زیر ۱ میلیون دلار درآمد)	۴۷ ثانیه	خیر	لوپ/افکت، کیفیت بالا
MusicGen (Meta)	۳۰۰M–۳.۳B	کد MIT / وزن CC-BY-NC	۳۰ ثانیه	خیر	مرجع پژوهشی، ملودی/استایل
YuE	۷B	Apache (کد) / CC-BY-NC (وزن)	چند دقیقه	بله	آهنگ کامل با آواز
DiffRhythm	۱B	Apache 2.0	تا ۴ دقیقه	بله	فوق‌سریع (تولید در چند ثانیه)
Tango 2	۱B	CC-BY-NC	۳۰ ثانیه	خیر	کیفیت بالای افکت/موسیقی
AudioLDM 2	۱B	CC-BY-NC	۱۰ ثانیه	خیر	عمومی صدا
MAGNeT	۳۰۰M–۱.۵B	CC-BY-NC	۳۰ ثانیه	خیر	سریع، غیراتورگرسیو

جمع‌بندی موسیقی: برای «آهنگ آمادهٔ انتشار» → Suno/Udio. برای «موسیقی پس‌زمینهٔ تجاری امن» → Firefly/Stable/ElevenLabs Music. برای «استقرار محلی و کنترل» → ACE-Step (بهترین باز) و DiffRhythm (سریع‌ترین).

---

۷. دستهٔ ۵ — تولید افکت صدا و Foley

مدل / سرویس	ورودی	مجوز/قیمت	ویژگی
ElevenLabs SFX v2	متن	اشتراکی/کردیت	کیفیت بالا، کتابخانهٔ صدا، همگام با ویدیو
Stable Audio Open / 2.5 API	متن	Community/ کردیت	افکت و لوپ، کیفیت خوب
Meta AudioGen	متن	CC-BY-NC	مرجع پژوهشی
TangoFlux	متن	Apache 2.0	۵۱۵M، سریع، کیفیت خوب
Woosh	متن	Apache 2.0	سبک، مخصوص افکت
MMAudio	ویدیو (+متن)	MIT	Foley خودکار برای ویدیو
HunyuanVideo-Foley (Tencent)	ویدیو	باز (تحقیقاتی)	همگامی دقیق با تصویر
AudioX	ویدیو/متن	باز	تولید صدا از ویدیو
Kling / Runway / Pika Foley	ویدیو	اشتراکی	درون ابزار ویدیو
Mirelo SFX	ویدیو	API	Foley حرفه‌ای

نکته: برای ویدیو، معیار اصلی «همگامی زمانی» است نه فقط کیفیت صدا. مدل‌های video-to-audio (MMAudio، HunyuanVideo-Foley) در این معیار از text-to-audio جلوترند.

---

۸. دستهٔ ۶ — سنتز آواز (Singing Voice)

گزینه	نوع	قیمت/مجوز	کیفیت	نکته
Synthesizer V Studio (Dreamtonics)	نرم‌افزار تجاری	۸۹ دلار + بانک صدا ۵۰–۱۰۰ دلار	بهترین کیفیت صنعتی	کنترل کامل فونتیک/ ویبراتو
Vocaloid 6 / CeVIO / Piapro	تجاری	۱۰۰–۳۰۰ دلار	بالا	اکوسیستم قدیمی و بزرگ
Suno / Udio	ابری	اشتراکی	بالا (آواز تولیدی)	کنترل محدود روی جزئیات
Kits.AI / Voicify / Jammable	ابری	اشتراکی	متوسط–بالا	کلون صدا روی آواز
DiffSinger	باز	Apache 2.0	متوسط–بالا	نیاز به داده/آموزش
ACE-Step / DiffRhythm / YuE	باز	Apache/NC	متوسط	آواز کامل درون آهنگ
RVC / so-vits-svc / Seed-VC	باز	MIT/AGPL	بالا (تبدیل)	تبدیل آواز موجود به صدای هدف

نکته: «سنتز آواز از صفر» (متن+نُت) با «تبدیل آواز» (خوانندهٔ واقعی → صدای دیگر) دو مسئلهٔ متفاوت‌اند. برای کیفیت استودیویی، Synthesizer V همچنان سرتر است؛ برای سرعت و هزینه، Suno.

---

۹. دستهٔ ۷ — درک و تحلیل صدا (Audio LLM)

مدل	مجوز	قابلیت	نکته
GPT-4o / GPT-5 audio (OpenAI)	API	شنیدن، استدلال، پاسخ صوتی، Realtime	گران‌ترین اما قوی‌ترین در گفت‌وگو
Gemini 2.5 / 3 (Google)	API	صدا + ویدیو + متن، پنجرهٔ بلند	یکپارچگی Gemini
Qwen3-Omni (Alibaba)	Apache 2.0	صدا/تصویر/متن، ۳۰B-A3B MoE	بهترین Omni باز
Qwen2.5-Omni	Apache 2.0	گفت‌وگوی بلادرنگ	سبک‌تر
Kimi-Audio (Moonshot)	MIT-ish	درک + تولید، ۱۳M ساعت داده	دقت بالا در بنچمارک
Step-Audio 2 mini	Apache 2.0	ASR + TTS + استدلال صوتی	چینی/انگلیسی قوی
Moshi (Kyutai)	CC-BY 4.0	گفت‌وگوی تمام‌دوطرفه (۲۰۰ میلی‌ثانیه)	تجربهٔ مکالمهٔ طبیعی
SALMONN / Audio Flamingo 3	تحقیقاتی	درک صداهای عمومی، موسیقی	غیرتجاری
GLM-4-Voice / MiniCPM-o	Apache 2.0	گفت‌وگوی سبک	لبه/موبایل

کاربردها: دستیار صوتی، تحلیل تماس، مانیتورینگ کارخانه، توضیح موسیقی، دسترس‌پذیری. معیارها: LongAudioBench، AudioBench، MMAU.

۱۰. دستهٔ ۸ — پردازش، جداسازی و بهبود صدا

ابزار / مدل	کار	مجوز	نکته
Demucs v4 (htdemucs)	جداسازی ۴/۶ استم	MIT	استاندارد باز؛ کیفیت خوب
BS-RoFormer / Mel-Band RoFormer	جداسازی استم	MIT-ish	بالاترین کیفیت جداسازی
MDX23C / UVR5	جداسازی + رابط گرافیکی	GPL/MIT	محبوب جامعه
LavaSR	ارتقای کیفیت/باند	Apache 2.0	بازسازی صدا
AudioSR	سوپررزولوشن صدا	MIT	۴۴.۱/۴۸kHz
Apollo	بازسازی صداهای خراب	باز	loss restoration
DeepFilterNet3	حذف نویز بلادرنگ	MIT	سبک، برای تماس
RNNoise	حذف نویز	BSD	فوق‌سبک
Resemble Enhance	بهبود گفتار	MIT/Apache	denoise + enhance
Adobe Podcast Enhance	بهبود گفتار	رایگان (وب)	کیفیت خوب، محدودیت
Auphonic / iZotope RX	مسترینگ/ترمیم	اشتراکی/ لایسنس	استاندارد حرفه‌ای
Krisp	حذف نویز/اکو	اشتراکی	SDK برای تماس

۱۱. تحلیل هزینه: چطور واقعاً مقایسه کنیم؟

۱۱.۱. هزینهٔ واحد کار (نرخ‌های تقریبی، نوامبر ۲۰۲۶)

کار	واحد	بازهٔ ابری	معادل یک ساعت کار
TTS ارزان (Polly/Azure/OpenAI tts-1)	میلیون کاراکتر	۴–۱۶ دلار	**۰.۴–۱.۵ دلار**
TTS میان‌رده (Cartesia/Deepgram/Fish)	میلیون کاراکتر	۱۵–۳۰ دلار	**۱.۴–۲.۷ دلار**
TTS پریمیوم (ElevenLabs/Hume)	میلیون کاراکتر	۶۰–۲۴۰ دلار	**۵–۲۲ دلار**
ASR ارزان (Soniox/Gladia/Speechmatics batch)	دقیقه	۰.۰۰۱–۰.۰۰۲ دلار	**۰.۰۶–۰.۱۲ دلار**
ASR میان‌رده (Deepgram/AssemblyAI)	دقیقه	۰.۰۰۲۵–۰.۰۰۵ دلار	**۰.۱۵–۰.۳۰ دلار**
ASR پریمیوم (Google/Azure/Rev)	دقیقه	۰.۰۱۶–۰.۰۲ دلار	**۰.۹۶–۱.۲ دلار**
موسیقی (Suno/Udio)	آهنگ	—	اشتراک ۱۰–۳۰ دلار/ماه
موسیقی API (Stable/Lyria)	دقیقه	۰.۰۲–۰.۱ دلار	**۱.۲–۶ دلار**
افکت صدا	تولید	۰.۰۱–۰.۱ دلار	متغیر

> یک ساعت گفتار ۹۰٬۰۰۰ کاراکتر؛ یک ساعت صدا = ۶۰ دقیقه. این دو را قاطی نکنید.

۱۱.۲. هزینهٔ self-host (TCO)

مورد	هزینهٔ تقریبی
GPU ابری (L4/A10G)	۰.۵–۱.۲ دلار به ازای ساعت
GPU ابری (A100/H100)	۲–۴ دلار به ازای ساعت
RTX 4090 (اجاره)	۰.۳–۰.۷ دلار به ازای ساعت
سرور اختصاصی با GPU	۳۰۰–۱٬۵۰۰ دلار/ماه
MLOps/نگهداری	۱۵–۳۰٪ هزینهٔ زیرساخت

جملهٔ کلیدی: Whisper large-v3-turbo روی یک L4 حدود ۳۰–۶۰ برابر بلادرنگ رونویسی می‌کند؛ یعنی هر GPU-ساعت ۳۰–۶۰ ساعت صدا **۰.۰۱–۰.۰۴ دلار به ازای هر ساعت صدا**. این عدد در مقیاس بزرگ (بیش از ۵۰۰ ساعت در ماه) از هر API ارزان‌تری پایین‌تر است — اما هزینهٔ مهندسی و پایداری را ندارد.

نقطهٔ سربه‌سر تقریبی: اگر ماهانه بیش از ۳۰۰–۵۰۰ ساعت صدا تولید/رونویسی می‌کنید و تیم فنی دارید، self-host را جدی بگیرید. زیر آن، API ارزان‌تر و کم‌دردسرتر است.

۱۱.۳. هزینهٔ پنهان

- **Egress/پهنای باند** در تولید انبوهٔ فایل صوتی.
- **Retry و کیفیت:** نرخ خطای TTS (تلفظ غلط، قطع‌شدن) باعث تولید دوباره و هزینهٔ مضاعف می‌شود.
- **قفل نسخه:** مدل‌های ابری بدون اطلاع تغییر می‌کنند؛ خروجی دیروز و امروز یکی نیست. برای محصول، نسخه را pin کنید یا خروجی را کش کنید.
- **حاکمیت داده:** صدا دادهٔ بیومتریک است؛ در برخی حوزه‌ها (سلامت، بانک) ارسال به ابر ممنوع است → self-host اجباری می‌شود.

---

۱۲. مجوزها: جدول تصمیم

مجوز	استفادهٔ تجاری	تغییر	ذکر منبع	نمونه
Apache 2.0	✅	✅	✅ (NOTICE)	Kokoro، CosyVoice، Dia، Orpheus، Qwen3-Omni
MIT	✅	✅	✅	Whisper، Piper، Chatterbox، Demucs، RVC
BSD	✅	✅	✅	RNNoise
CC-BY 4.0	✅	✅	✅	Moshi، Parakeet/Canary
CC-BY-NC	❌	✅	✅	MusicGen weights، F5-TTS weights، YuE weights
Stability Community	✅ زیر ۱ میلیون دلار درآمد	✅	✅	Stable Audio Open
Llama/Community اختصاصی	مشروط	مشروط	—	برخی مدل‌های متا/مایکروسافت
CPML (Coqui)	❌	✅	—	XTTS-v2
AGPL	✅ (با تعهد سورس سرویس)	✅	✅	so-vits-svc
اختصاصی ابری	طبق قرارداد	❌	—	ElevenLabs، Suno، Deepgram

قاعدهٔ طلایی: مجوز **مخزن کد** با مجوز **وزن‌ها** یکی نیست. F5-TTS کد MIT دارد اما وزن CC-BY-NC؛ Fish Speech کد باز دارد اما وزن غیرتجاری. همیشه فایل `LICENSE` وزن‌ها (مثلاً در Hugging Face) را بخوانید.

۱۳. راهنمای انتخاب بر اساس سناریو

سناریو	انتخاب اول	جایگزین	چرا
دستیار/ایجنت تلفنی	Cartesia Sonic-3 + Deepgram Nova-3	ElevenLabs Flash + AssemblyAI	تأخیر <۳۰۰ میلی‌ثانیه، هزینهٔ قابل پیش‌بینی
کتاب صوتی فارسی	Azure Neural (fa-IR) + ویرایش	ElevenLabs (تست)	تلفظ و پوشش رسمی فارسی
پادکست/ویدیوی انگلیسی	ElevenLabs v3	PlayHT، Hume	بیان و کلونینگ
دوبلهٔ فیلم/سریال	Respeecher / ElevenLabs + پردازش	Synthesizer V برای آواز	کیفیت و مجوز صدا
تماس مشتریان (ASR + تحلیل)	AssemblyAI / Deepgram	Speechmatics	دیاریزیشن + تحلیل مکالمه
رونویسی انبوه ارزان	Whisper large-v3-turbo (self-host)	Soniox API	هزینهٔ پایین در مقیاس
زیرنویس فارسی	Whisper + بازبینی انسانی	Azure fa-IR	دقت قابل قبول، هزینهٔ کم
موسیقی پس‌زمینهٔ تجاری	Adobe Firefly / Stable Audio	ACE-Step (self-host)	ایمنی حقوقی
آهنگ کامل با آواز	Suno v5 / Udio	ACE-Step / YuE	کیفیت و سرعت
افکت صدا برای بازی	ElevenLabs SFX / Stable Audio	TangoFlux، Woosh	تنوع و کنترل
Foley خودکار ویدیو	MMAudio / HunyuanVideo-Foley	Kling Foley	همگامی با تصویر

سناریو	انتخاب اول	جایگزین	چرا
حذف نویز تماس	DeepFilterNet3 / Krisp	RNNoise	بلادرنگ و سبک
جداسازی استم برای ریمیکس	BS-RoFormer / Demucs	UVR5	کیفیت جداسازی
پژوهش و فاین‌تیون	Whisper + Qwen3-Omni + ACE-Step	Kokoro، Parakeet	باز، قابل تغییر

---

۱۴. وضعیت فارسی: واقعیت‌ها و شکاف‌ها

ASR فارسی:

- **Whisper large-v3** روی فارسی کار می‌کند (WER حدود ۱۰–۱۵٪ در گفتار تمیز، بالاتر در محاوره/نویز). مشکلات رایج: اعداد، نیم‌فاصله، «ی/ک» عربی، نام‌های خاص.
- **Azure fa-IR** و **Google fa-IR** پشتیبانی رسمی دارند و برای متن‌های رسمی/خبری خوب‌اند.
- **Speechmatics** فارسی را پشتیبانی می‌کند؛ **Vosk fa** سبک اما کم‌دقت؛ **MMS** پوشش دارد ولی کیفیت پایین.
- برای دقت بالا در فارسی محاوره‌ای، فاین‌تیون Whisper روی دادهٔ برچسب‌دار داخلی بهترین مسیر است.

TTS فارسی:

- **Azure** (صداهای fa-IR) و **Google** گزینه‌های رسمی و پایدارند.
- **ElevenLabs** فارسی را در مدل‌های چندزبانه پوشش می‌دهد اما کیفیت تلفظ را باید روی واژگان خودتان تست کنید (اعداد، اصطلاحات، اسم‌ها).
- **باز:** Piper fa_IR (سریع/سبک/ماشینی)، مدل‌های جامعه‌محور VITS/Coqui آموزش‌دیده روی **ManaTTS** و **Common Voice fa**؛ کیفیت به داده و مدت آموزش بستگی دارد.
- **شکاف اصلی:** هیچ مدل باز «SOTA چندزبانه» فارسی را در سطح انگلیسی پوشش نمی‌دهد. برای محصول فارسی، ترکیب «مدل باز فاین‌تیون‌شده + فرهنگ تلفظ» واقع‌بینانه‌تر از انتظار از مدل عمومی است.

نکات فنی فارسی: نرمال‌سازی متن (ارقام، نیم‌فاصله، «آ/ا»)، فرهنگ تلفظ برای اسم‌های خاص، و ارزیابی با مجموعهٔ داخلی (نه فقط MOS عمومی).

---

۱۵. بنچمارک‌ها: کجا را نگاه کنیم؟

حوزه	بنچمارک/تابلو	نکته
TTS	**TTS Arena (Hugging Face)، Artificial Analysis Speech Arena**	رأی انسانی؛ همبستگی بالا با ادراک
ASR	**Open ASR Leaderboard (HF)**	WER روی مجموعه‌های انگلیسی؛ برای فارسی معتبر نیست
ASR چندزبانه	**FLEURS، Common Voice**	پوشش زبان‌ها
درک صدا	**MMAU، AudioBench، LongAudioBench**	استدلال و درک طولانی
جداسازی	**MUSDB18 / SDR**	کیفیت استم
موسیقی	ارزیابی انسانی + FAD	خودکار کافی نیست

هشدار: بنچمارک عمومی ≠ عملکرد در دامنهٔ شما. همیشه یک «ست آزمون کوچک از دادهٔ خودتان» (۵۰–۲۰۰ نمونه) بسازید و مدل‌ها را روی آن بسنجید. این تنها معیار قابل اتکاست.

---

۱۶. ریسک‌ها و ملاحظات حقوقی/اخلاقی

1. **کلونینگ صدا:** نیاز به رضایت صریح، ثبت لاگ، و افشای مصنوعی‌بودن. در EU AI Act و قوانین ایالتی (تنسی، کالیفرنیا) الزامات شفافیت وجود دارد.
2. **حق نشر موسیقی:** Suno/Udio در ۲۰۲۵ با ناشران توافق کردند؛ اما مدل‌های باز آموزش‌دیده روی دادهٔ محافظت‌شده ریسک دارند. برای محصول، مدل با «مجوز دادهٔ شفاف» انتخاب کنید.
3. **دادهٔ بیومتریک:** صدا تحت GDPR/CCPA دادهٔ حساس است؛ نگهداری و انتقال آن نیازمند DPIA است.
4. **قفل فروشنده:** وابستگی به یک API با تغییر قیمت/نسخه. راهکار: لایهٔ انتزاع + قابلیت جایگزینی مدل.
5. **توهم و خطای ایمنی:** مدل‌های صوتی می‌توانند عبارات خطرناک تولید کنند؛ فیلتر خروجی و لاگ لازم است.
6. **کیفیت در زبان‌های کم‌منبع:** افت شدید نسبت به انگلیسی؛ انتظارات را مدیریت کنید.

---

۱۷. چک‌لیست ارزیابی عملی (قبل از انتخاب)

- □ ۵۰–۲۰۰ نمونهٔ واقعی از دادهٔ خودتان (شامل نویز، لهجه، اصطلاحات).
- □ معیار موفقیت عددی: WER هدف، MOS هدف، TTFA هدف، نرخ خطای تلفظ.
- □ تست A/B کور بین ۳ مدل نهایی.
- □ محاسبهٔ هزینه بر واحد کار واقعی (با نرخ retry).
- □ بررسی مجوز وزن‌ها برای استفادهٔ تجاری.
- □ آزمون پایداری: همان ورودی، ۱۰ بار، بررسی تنوع خروجی.
- □ آزمون استریم/تأخیر در شبکهٔ واقعی (نه فقط بنچمارک).
- □ برنامهٔ خروج (export) و جایگزینی مدل.

---

۱۸. منابع و لینک‌های کلیدی

تابلوها و بنچمارک:

- Artificial Analysis — Text to Speech Leaderboard
- Hugging Face — Open ASR Leaderboard
- Hugging Face — TTS Arena

مقایسه و قیمت (برای راستی‌آزمایی):

- Deepgram Pricing
- ElevenLabs Pricing
- OpenAI API Pricing
- AssemblyAI Pricing
- Google Cloud TTS Pricing
- Azure Speech Pricing
- AWS Polly Pricing
- Suno Pricing
- Future AGI — مقایسهٔ TTS 2026
- Future AGI — مقایسهٔ STT 2026

مدل‌های باز (نمونه):

- (82M-https://huggingface.co/hexgrad/Kokoro)[82M-Kokoro]
- Chatterbox
- CosyVoice
- F5-TTS
- ACE-Step
- Demucs
- Qwen3-Omni

- Whisper

پیوست: ۱۰ انتخاب سریع

اگر...	انتخاب کن
کم‌هزینه‌ترین TTS با کیفیت خوب	Kokoro-82M (self-host) یا OpenAI tts-1
بهترین TTS تجاری	ElevenLabs v3
بهترین ASR تجاری	Deepgram Nova-3 / AssemblyAI Universal-3
بهترین ASR باز	Whisper large-v3-turbo یا Parakeet-TDT
بهترین موسیقی کامل	Suno v5
بهترین موسیقی باز	ACE-Step
بهترین افکت از متن	ElevenLabs SFX v2
بهترین Foley از ویدیو	MMAudio / HunyuanVideo-Foley
بهترین درک صدا باز	Qwen3-Omni
بهترین جداسازی استم	BS-RoFormer